

Пусть теперь  $\xi$  – СВНТ. Не известна плотность ее распределения  $f_{\xi}(x)$ . Для оценки плотности распределения по выборке  $\xi_1, \xi_2, \dots, \xi_n$  сделаем следующее:

- разобьем область значений случайной величины  $\xi$  на интервалы длины  $h_i$  ( $i = 1, 2, \dots, s$ );
- найдем  $x_i^*$  – середины  $i$ -го интервала;
- подсчитаем число  $V_i$  – число элементов в выборке, попавших в  $i$ -ый интервал;
- вычислим значение  $f_n(x_i^*) = \frac{V_i}{nh_i}$ , являющееся оценкой плотности распределения случайной величины в точке  $x_i^*$ .


**Определение.** Фигура, составленная из прямоугольников с основаниями  $h_i$  ( $i = 1, 2, \dots, s$ ) и высотами  $\frac{V_i}{nh_i}$ , называется **гистограммой**.

**Определение.** Эмпирической функцией распределения назовем функцию распределения СВДТ, принимающей значения середин выбранных интервалов ( $x_i^*$ ) с вероятностями, равными  $\frac{V_i}{n}$ .


Пример. Пусть имеется выборка объема 100 из генеральной совокупности с теоретической плотностью распределения  $f_{\xi}(x)$ . Результаты измерений занесены в таблицу:

№ интервала $i$	Границы интервала $(x_i, x_{i+1})$	Середина интервала $x_i^*$	Число элементов, попавших в интервал $V_i$	$f_n(x_i^*) = \frac{V_i}{nh_i}$
1	(0, 2)	1	20	0,1
2	(2, 4)	3	50	0,25
3	(4, 6)	5	30	0,15

Гистограмма



## Эмпирическая функция распределения



## §2. Точечные оценки параметров распределений.

Смысл точечной оценки: исследуемая величина считается приближенно равной вычисляемому значению.

**Определение.** Пусть  $\xi_1, \xi_2, \dots, \xi_n$  – наблюдаемые значения случайной величины  $\xi$ .

- $\bar{\xi} = \frac{1}{n} \sum_{i=1}^n \xi_i$  – выборочное среднее случайной величины  $\xi$ .
- $s^2 = \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi})^2$  – выборочная дисперсия.
- $s_1^2 = \frac{1}{n-1} \sum_{i=1}^n (\xi_i - \bar{\xi})^2$  – исправленная выборочная дисперсия.

**Замечание.** По своей сути, точечные оценки случайной величины сами являются случайными величинами, но в статистических расчетах вместо случайных величин подставляют их числовые значения. Для выборочного среднего принято обозначение  $\bar{X}_b$ .

### Типы точечных оценок.

Пусть  $\xi_i$  – случайная величина, представляющая результат  $i$ -го испытания величины  $\xi$ ,  $a$  – оцениваемый параметр,  $\tilde{a}$  – его точечная оценка. Тогда эта оценка является функцией от случайных величин  $\xi_1, \xi_2, \dots, \xi_n$ , то есть  $\tilde{a} = \varphi(\xi_1, \xi_2, \dots, \xi_n)$ .

**Определение.** Точечная оценка  $\tilde{a}$  называется **состоятельной**, если  $\forall \varepsilon > 0 \lim_{n \rightarrow \infty} P(a - \varphi(\xi_1, \xi_2, \dots, \xi_n) < \varepsilon) = 1$ , в этом случае говорят, что точечная оценка  $\tilde{a}$  сходится к оцениваемому параметру по вероятности.

**Определение.** Точечная оценка  $\tilde{a}$  называется **несмещенной**, если ее математическое ожидание равно оцениваемому параметру, то есть  $M\tilde{a} = a$ .

**Определение.** Точечная оценка  $\tilde{a}$  называется **эффeктивной**, если ее дисперсия минимальна.

Справедлива следующая теорема.

**Теорема 1.** Выборочное среднее  $\bar{\xi} = \frac{1}{n} \sum_{i=1}^n \xi_i$  – состоятельная несмещенная оценка математического ожидания. В случае, когда случайная величина  $\xi$  подчинена нормальному закону распределения, то эта оценка является также эффективной.

**Теорема 2.** Выборочная дисперсия  $s^2 = \frac{1}{n} \sum_{i=1}^n (\xi_i - \bar{\xi})^2$  – состоятельная оценка дисперсии  $D\xi$ , которая, однако, не является несмещенной. Исправленная выборочная дисперсия  $s_1^2 = \frac{1}{n-1} \sum_{i=1}^n (\xi_i - \bar{\xi})^2$  является состоятельной несмещенной оценкой дисперсии.

**Замечание.** Легко заметить, что  $s_1^2 = \frac{n}{n-1} s^2$ ,  $\frac{n}{n-1} \xrightarrow{n \rightarrow \infty} 1$ , и при больших объемах выборки  $s_1^2 \approx s^2$ . При малых значениях  $n$  лучше брать исправленную дисперсию  $s_1^2$ .

### §3. Интервальные оценки параметров распределений.

Смысл интервальной оценки: исследуемая величина с заданной вероятностью попадает в данный интервал.

Пусть  $\xi$  – случайная величина, подчиняющаяся нормальному закону  $N(a, \sigma)$ .

Неизвестная плотность распределения имеет вид:  $f_{\xi}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}$ , при этом неизвестны

именно параметры распределения. Пусть  $\xi_i$  – случайная величина, представляющая результат  $i$ -го испытания величины  $\xi$ , тогда  $M\xi_i = a$ ,  $D\xi_i = \sigma^2$ . Можно доказать, что выборочное среднее

$\bar{\xi} = \frac{1}{n} \sum_{i=1}^n \xi_i$  также является нормально распределенной случайной величиной с числовыми

характеристиками  $M\bar{\xi} = a$ ,  $D\bar{\xi} = \frac{\sigma^2}{n}$ . То есть выборочное среднее подчиняется закону

$$N\left(a, \frac{\sigma}{\sqrt{n}}\right).$$

Рассмотрим вероятность того, что выборочное среднее, как нормальная случайная величина отклоняется от своего математического ожидания на некоторую величину  $\delta > 0$ .

$$P(|\bar{\xi} - a| < \delta) = P(a - \delta < \bar{\xi} < a + \delta) = \Phi\left(\frac{a + \delta - a}{\sqrt{D\bar{\xi}}}\right) - \Phi\left(\frac{a - \delta - a}{\sqrt{D\bar{\xi}}}\right) = 2\Phi\left(\frac{\delta\sqrt{n}}{\sigma}\right). (*)$$

Обозначим  $t = \frac{\delta\sqrt{n}}{\sigma}$ , тогда  $P(|\bar{\xi} - a| < \delta) = 2\Phi(t)$ .

Вероятность  $2\Phi(t)$  называют доверительной вероятностью. Обычно считают, что  $2\Phi(t) \approx 1$ , или  $2\Phi(t) = 1 - \alpha$ , где  $\alpha$  — достаточно маленькое положительное число, называемое уровнем значимости.

Доверительный интервал — интервал, который с заданной доверительной вероятностью покрывает оцениваемый параметр.

Пусть известен параметр  $\sigma$ , а искомым параметром является  $a$ .  $t = \frac{\delta\sqrt{n}}{\sigma} \Rightarrow \delta = \frac{\sigma t}{\sqrt{n}}$ , а тогда, если раскрыть модуль в выражении (\*) по-другому, получим:

$$P(\bar{\xi} - \delta < a < \bar{\xi} + \delta) = P(a \in (\bar{\xi} - \delta, \bar{\xi} + \delta)) = 2\Phi(t) = 1 - \alpha.$$

Интервал  $(\bar{\xi} - \delta, \bar{\xi} + \delta)$  является доверительным интервалом. Для нахождения числа  $\delta$  нужно по таблице функции Лапласа найти такое значение  $t$ , для которого  $\Phi(t) = \frac{1 - \alpha}{2}$ .

**Замечание.** Если параметр  $\sigma$  также не известен, то можно заменить, используя исправленную дисперсию, то есть  $\sigma \approx \sqrt{s_1^2}$ .

#### §4. Статистическая проверка гипотезы о характере распределения. Критерий Пирсона (критерий $\chi^2$ ).

Пусть  $\xi_1, \xi_2, \dots, \xi_n$  — выборка из генеральной совокупности с теоретической функцией распределения  $F_\xi(x)$ . Выдвигаем гипотезу  $H_0$ : выборка  $\xi_1, \xi_2, \dots, \xi_n$  соответствует случайной величине с теоретической функцией распределения  $F_0(x)$ .  $F_0(x)$  — некоторая конкретная функция. Для проверки гипотезы  $H_0$  используем критерий Пирсона.

1. Найдем размах выборки и выберем подходящий отрезок, в котором принимает значения случайная величина. Этот отрезок разобьем на  $r$  интервалов  $\Delta_1, \Delta_2, \dots, \Delta_r$ ,  $\Delta_i = (a_i, a_{i+1})$ .

2. Найдем вероятность попадания случайной величины, распределенной по закону  $F_0(x)$  в

$$\text{каждый из этих интервалов. } p_i = P(\xi \in \Delta_i) = F_0(a_{i+1}) - F_0(a_i) = \int_{a_i}^{a_{i+1}} f_0(x) dx.$$

3. Пусть  $v_i$  — число элементов в выборке, которые попали в  $\Delta_i$  (эмпирическая частота). Число значений случайной величины, попавшей в интервал  $\Delta_i$  — случайная величина, подчиняющаяся биномиальному закону с параметрами  $n$  — число испытаний (число измерений случайной величины) и  $p_i$  — вероятность успеха (вероятность попадания в нужный интервал). Математическое ожидание случайной величины, распределенной по данному биномиальному закону, равно  $np_i$ . Это число  $np_i$  суть ожидаемая (теоретическая) частота.

4. За меру отклонения распределения выборки от гипотетического принимается величина  $\chi^2_{\text{в}}$  («хи квадрат выборочное»),  $\chi^2_{\text{в}} = \sum_{i=1}^r \frac{(v_i - np_i)^2}{np_i}$ . Пирсон доказал, что в случае справедливости гипотезы  $H_0$  распределение случайной величины  $\chi^2_{\text{в}}$  при  $n \rightarrow \infty$  сходится к известному распределению  $\chi^2$  («хи квадрат») с  $r - 1$  степенями свободы.
5. Зададим уровень значимости  $\alpha$ . Обычно  $\alpha = 0,05$ . По таблице распределений  $\chi^2$  с  $r - 1$  степенями свободы находим такое значение  $\chi^2_{\alpha, r-1}$ , что  $P(\chi^2 > \chi^2_{\alpha, r-1}) = \alpha$ .
6. По имеющейся выборке вычисляем значение  $\chi^2_{\text{в}}$ . Если окажется, что  $\chi^2_{\text{в}} > \chi^2_{\alpha, r-1}$ , то такое отклонение считается значимым, и мы с уровнем значимости  $\alpha$  отвергаем гипотезу  $H_0$ , то есть с вероятностью 95% эта гипотеза не является верной. Если же  $\chi^2_{\text{в}} \leq \chi^2_{\alpha, r-1}$ , то гипотеза принимается на уровне значимости  $\alpha$ .

#### Важные замечания.

- В приложениях интервалы  $\Delta_i$  выбираются так, чтобы число элементов в каждом из них было не очень малым, то есть чтобы теоретическая частота  $np_i \geq 5$ .
- Интервалы  $\Delta_i$  не обязательно должны быть одинаковой длины.
- Если распределение зависит от неизвестных параметров, то вероятности  $p_i$  попадания в интервалы  $\Delta_i$  вычисляем, заменяя эти параметры достаточно хорошими точечными оценками. В этом случае число степеней свободы будет равно  $r - l - 1$ , где  $r$  — число интервалов, оставшихся после объединения,  $l$  — число неизвестных параметров распределения.

Далее вы можете увидеть статистическую проверку гипотезы о распределении баллов за первый коллоквиум по теории вероятностей студентов 2 курса (2012 год).

